

Gramatyki bezkontekstowe

Języki formalne i techniki translacji - Wykład 4

Maciek Gębala

23 października 2018

Maciek Gębala Gramatyki bezkontekstowe

Gramatyki bezkontekstowe

Definicja: Gramatyka bezkontekstowa G to czwórka $G = (N, T, P, S)$ gdzie

N - skończony zbiór zmiennych (nieterminale),

T - skończony zbiór symboli końcowych (terminale, alfabet),

P - skończony zbiór produkcji postaci $A \rightarrow \alpha$, gdzie $A \in N$ i $\alpha \in (N \cup T)^*$,

$S \in N$ - symbol początkowy.

Relacja wyprowadzenia \Rightarrow_G

Jeśli $A \rightarrow \beta$ jest produkcją w G i $\alpha, \gamma \in (N \cup T)^*$ to $\alpha A \gamma \Rightarrow_G \alpha \beta \gamma$ ($\alpha \beta \gamma$ jest bezpośrednio wyprowadzany z $\alpha A \gamma$ w gramatyce G).

Będziemy pisać tylko \Rightarrow gdy gramatyka jest oczywista.

\Rightarrow^* - zwrotne i przechodnie domknięcie \Rightarrow .

Maciek Gębala Gramatyki bezkontekstowe

Gramatyki bezkontekstowe

Definicja: Język generowany przez G to

$$L(G) = \{ w : w \in T^* \wedge S \Rightarrow_G^* w \}.$$

Język L nazywamy bezkontekstowym jeśli jest identyczny z $L(G)$ dla pewnej gramatyki bezkontekstowej G .

G_1 i G_2 są równoważne jeżeli $L(G_1) = L(G_2)$.

Przykład

$$G = (\{S\}, \{0, 1\}, \{S \rightarrow \varepsilon, S \rightarrow 0, S \rightarrow 1, S \rightarrow 0S0, S \rightarrow 1S1\}, S)$$

lub inaczej (krócej) zapisując

$$S \rightarrow \varepsilon | 0 | 1 | 0S0 | 1S1$$

Wyprowadzenie słowa 0110:

$$S \Rightarrow 0S0 \Rightarrow 01S10 \Rightarrow 0110$$

Maciek Gębala Gramatyki bezkontekstowe

Drzewo wyprowadzenia

Drzewo o następujących własnościach

- 1 każdy wierzchołek ma etykietę z $N \cup T \cup \{\varepsilon\}$,
- 2 korzeń ma etykietę S (symbol początkowy),
- 3 wierzchołki wewnętrzne mają etykiety z N ,
- 4 jeżeli wierzchołek wewnętrzny ma etykietę A a jego synowie od lewej mają kolejno etykiety X_1, \dots, X_n to $A \rightarrow X_1 \dots X_n$ jest produkcją w P .

Jeśli konkatenacja wszystkich liści czytanych od lewej do prawej daje α to drzewo nazywamy drzewem wyprowadzenia α .

Przykład drzewa wyprowadzenia (na tablicy)

Słowo $id + id * id$ dla gramatyki $E \rightarrow E + E | E * E | id$.

Maciek Gębala Gramatyki bezkontekstowe

Notatki

Notatki

Notatki

Notatki

Drzewo wyprowadzenia

Twierdzenie. Niech $G = (N, T, P, S)$ będzie gramatyką bezkontekstową. Wtedy $S \Rightarrow^* \alpha \iff$ istnieje drzewo wyprowadzenia α w gramatyce G .

Dowód

Indukcja względem ilości wierzchołków wewnętrznych w drzewie.

Definicja. Jeżeli w każdym kroku wyprowadzenia stosujemy produkcję do nieterminala leżącego najbardziej na lewo (prawo), to wyprowadzenie nazywamy lewostronnym (prawostronnym). Jeżeli $w \in L(G)$ to w ma co najmniej jedno drzewo wyprowadzenia. Każdemu drzewu wyprowadzenia odpowiada dokładnie jedno wyprowadzenie lewostronne (prawostronne).

Definicja. Jeśli w $L(G)$ istnieje słowo mające dwa różne drzewa wyprowadzenia to G nazywamy wieloznaczną.

Maciek Gębala Gramatyki bezkontekstowe

Notatki

Usuwanie symboli bezużytecznych

Niech L – niepusty język bezkontekstowy. Wtedy L można wygenerować za pomocą gramatyki G o następujących własnościach

- 1 każdy symbol pojawia się w wyprowadzeniu jakiegoś słowa z L ,
- 2 nie ma produkcji postaci $A \rightarrow B$ (produkcie jednostkowe), gdzie $A, B \in N$.

Co więcej, jeśli $\varepsilon \notin L$ to w G nie ma produkcji postaci $A \rightarrow \varepsilon$.

Symbol X jest użyteczny jeśli istnieje wyprowadzenie postaci $S \Rightarrow^* \alpha X \gamma \Rightarrow^* w$ ($w \in T^*$), w p.p. X jest bezużyteczny.

Maciek Gębala Gramatyki bezkontekstowe

Notatki

Usuwanie symboli bezużytecznych

Lemat. Dla dowolnej gramatyki bezkontekstowej $G = (N, T, P, S)$ z $L(G) \neq \emptyset$ można efektywnie znaleźć równoważną gramatykę bezkontekstową $G' = (N', T, P', S)$ t.ż. dla dowolnego $A \in N'$ istnieje $w \in T^*$ t.ż. $A \Rightarrow^* w$.

Dowód (szkic)

- 1 $N_s \leftarrow \emptyset$
 $N_n \leftarrow \{A : (A \rightarrow w) \in P \wedge w \in T^*\}$
- 2 while $N_s \neq N_n$ do
 $N_s \leftarrow N_n$
 $N_n \leftarrow N_s \cup \{A : (A \rightarrow \alpha) \in P \wedge \alpha \in (T \cup N_s)^*\}$
- 3 $N' \leftarrow N_n$
 $P' \leftarrow \{(A \rightarrow \alpha) \in P : A \in N_n \wedge \alpha \in (T \cup N_s)^*\}$

Maciek Gębala Gramatyki bezkontekstowe

Notatki

Usuwanie symboli bezużytecznych

Lemat. Dla dowolnej gramatyki bezkontekstowej $G = (N, T, P, S)$ można efektywnie znaleźć równoważną gramatykę bezkontekstową $G' = (N', T', P', S)$ t.ż. dla każdego $X \in (N' \cup T')$ istnieją $\alpha, \beta \in (N' \cup T')^*$ t.ż. $S \Rightarrow^* \alpha X \beta$.

Dowód (szkic)

- 1 $N' \leftarrow \{S\}$
- 2 while można zmienić N' do
 Jeśli $A \in N'$ i $A \rightarrow \alpha_1 | \dots | \alpha_n$ to dodaj wszystkie nieterminaly z $\alpha_1, \dots, \alpha_n$ do N' a terminale do T' .
- 3 Do P' przenieś tylko te produkcje z P które zawierają symbole z $N' \cup T' \cup \{\varepsilon\}$.

Twierdzenie. Każdy niepusty język bezkontekstowy jest generowany przez gramatykę bezkontekstową nie zawierającą symboli bezużytecznych.

Maciek Gębala Gramatyki bezkontekstowe

Notatki

Twierdzenie. Jeżeli $L = L(G)$ dla gramatyki bezkontekstowej $G = (N, T, P, S)$ to dla $L \setminus \{\varepsilon\}$ istnieje gramatyka bezkontekstowa G' nie zawierająca ε -produkcji i symboli bezużytecznych.

Dowód

Symbole bezużyteczne usunęliśmy dzięki poprzedniemu twierdzeniu. Dla każdego nieterminala A sprawdzamy czy $A \Rightarrow^* \varepsilon$. Jeśli tak to każdą produkcję $B \rightarrow \alpha A \beta$ zastępujemy produkcjami $B \rightarrow \alpha A \beta$ i $B \rightarrow \alpha \beta$ (ale nie dołączamy $B \rightarrow \varepsilon$). Następnie usuwamy wszystkie ε -produkcje.

Usuwanie produkcji jednostkowych

Twierdzenie. Każdy język bezkontekstowy nie zawierający ε jest definiowany za pomocą gramatyki nie zawierającej symboli bezużytecznych, ε -produkcji i produkcji jednostkowych.

Dowód

Jeżeli dla nieterminala A mamy $A \Rightarrow^* B$ i $A \neq B$ to dla każdej niejednostkowej produkcji $B \rightarrow \alpha$ dodajemy produkcję $A \rightarrow \alpha$. Następnie usuwamy produkcje jednostkowe.

Postać normalna Chomsky'ego

Twierdzenie. Dowolny język bezkontekstowy nie zawierający ε jest generowany przez gramatykę której wszystkie produkcje są postaci $A \rightarrow BC$ lub $A \rightarrow a$, gdzie $A, B, C \in N$ i $a \in T$.

Dowód (konstrukcja)

Niech G będzie gramatyką bez symboli bezużytecznych, ε -produkcji i produkcji jednostkowych. Wtedy jeśli prawa strona produkcji jest długości 1 to jest postaci $A \rightarrow a$. Dla pozostałych produkcji wykonujemy następujące operacje:

1. Jeśli po prawej stronie występuje terminal a to dodajemy do N nowy nieterminal C_a a do produkcji $C_a \rightarrow a$ i zastępujemy a przez C_a .
2. Teraz jeśli prawa strona produkcji jest dłuższa niż 1 to zawiera tylko nieterminal. Jeśli jest postaci $A \rightarrow B_1 \dots B_n$ dla $n > 2$, to tworzymy nowe nieterminaly D_1, \dots, D_{n-2} i zastępujemy tą produkcję przez $A \rightarrow B_1 D_1, D_1 \rightarrow B_2 D_2, \dots, D_{n-3} \rightarrow B_{n-2} D_{n-2}, D_{n-2} \rightarrow B_{n-1} B_n$.

Przykład

$$\begin{aligned} S &\rightarrow bA|aB \\ A &\rightarrow bAA|aS|a \\ B &\rightarrow aBB|bS|b \end{aligned}$$

Przykład na tablicy.

**Postać normalna Chomsky'ego**

$$\begin{aligned} S &\rightarrow C_b A | C_a B \\ A &\rightarrow C_b D_A | C_a S | a \\ B &\rightarrow C_a D_B | C_b S | b \\ C_a &\rightarrow a \\ C_b &\rightarrow b \\ D_A &\rightarrow AA \\ D_B &\rightarrow BB \end{aligned}$$

Postać normalna Greibach

Produkcje są postaci $A \rightarrow a\alpha$, gdzie $A \in N$, $a \in T$ i $\alpha \in N^*$.

Określmy jako A -produkcie wszystkie produkcje z nieterminaliem A po lewej stronie.

Lemat 1. Niech $G = (N, T, P, S)$ będzie gramatyką bezkontekstową. Niech $A \rightarrow \alpha_1 B \alpha_2$ będzie produkcją w P i niech $B \rightarrow \beta_1 | \dots | \beta_r$ będzie zbiorem wszystkich B -produkcji. Niech $G' = (N, T, P', S)$ będzie gramatyką otrzymaną z G przez usunięcie produkcji $A \rightarrow \alpha_1 B \alpha_2$ i dodanie produkcji $A \rightarrow \alpha_1 \beta_1 \alpha_2 | \dots | \alpha_1 \beta_r \alpha_2$. Wówczas $L(G) = L(G')$.

Dowód

Dowód po strukturze drzewa wyprowadzenia.

Maciek Gębala

Gramatyki bezkontekstowe

Notatki

Postać normalna Greibach

Lemat 2. Niech $G = (N, T, P, S)$ będzie gramatyką bezkontekstową. Niech $A \rightarrow A\alpha_1 | \dots | A\alpha_r$ będzie zbiorem tych A -produkcji których prawe strony zaczynają się od A . Niech $A \rightarrow \beta_1 | \dots | \beta_s$ będzie zbiorem pozostałych A -produkcji. Niech $G' = (N \cup \{B\}, T, P', S)$ będzie gramatyką utworzoną poprzez dodanie nowego nieterminala B i zastąpienie wszystkich A -produkcji przez następujące produkcje

$$A \rightarrow \beta_i | \beta_i B, \quad 1 \leq i \leq s$$

$$B \rightarrow \alpha_j | \alpha_j B, \quad 1 \leq j \leq r$$

Wtedy $L(G) = L(G')$.

Maciek Gębala

Gramatyki bezkontekstowe

Notatki

Postać normalna Greibach

Dowód

W wyprowadzeniu lewostronnym ciąg produkcji postaci $A \rightarrow A\alpha_i$ musi kiedyś skończyć się produkcją $A \rightarrow \beta_j$

$$A \Rightarrow A\alpha_{i_1} \Rightarrow A\alpha_{i_2}\alpha_{i_1} \Rightarrow \dots \Rightarrow A\alpha_{i_n}\alpha_{i_{n-1}}\dots\alpha_{i_1} \Rightarrow \beta_j\alpha_{i_n}\alpha_{i_{n-1}}\dots\alpha_{i_1}$$

Można to zastąpić przez

$$A \Rightarrow \beta_j B \Rightarrow \beta_j \alpha_{i_n} B \Rightarrow \dots \Rightarrow \beta_j \alpha_{i_n} \dots \alpha_{i_2} B \Rightarrow \beta_j \alpha_{i_n} \dots \alpha_{i_1}$$

Ponieważ transformacja ta jest obustronna to $L(G) = L(G')$

Maciek Gębala

Gramatyki bezkontekstowe

Notatki

Postać normalna Greibach

Twierdzenie. Każdy język bezkontekstowy L nie zawierający ε jest generowany przez pewną gramatykę w której każda produkcja jest postaci $A \rightarrow a\alpha$, gdzie $a \in T$, $A \in N$ i $\alpha \in N^*$.

Dowód

Niech $G = (N, T, P, S)$ będzie gramatyką w postaci normalnej Chomsky'ego. Załóżmy, że $N = \{A_1, \dots, A_n\}$. Modyfikujemy produkcje tak aby jeśli produkcja jest postaci $A_i \rightarrow A_j \alpha$ to $i < j$.

for $k \rightarrow 1$ to n do
 for $j \rightarrow 1$ to $k-1$ do

1. Za każdą produkcję postaci $A_k \rightarrow A_j \alpha$ wstaw produkcje $A_k \rightarrow \beta \alpha$ dla wszystkich produkcji $A_j \rightarrow \beta$ (Lemat 1).
2. Dla produkcji postaci $A_k \rightarrow A_k \alpha$ wykonaj Lemat 2 używając nowy nieterminal B_k .

Maciek Gębala

Gramatyki bezkontekstowe

Notatki

Postać normalna Greibach

Dowód cd.

Po wykonaniu tego algorytmu mamy gramatykę równoważną o produkcjach w postaci:

- $A_i \rightarrow A_j \gamma$, gdzie zawsze $i < j$,
- $A_i \rightarrow a \gamma$, gdzie $a \in T$,
- $B_i \rightarrow \gamma$, gdzie $\gamma \in (N \cup \{B_1, \dots, B_{i-1}\})^*$.

Zauważmy, że A_n -produkcje muszą zaczynać się terminalem. Teraz rozważmy A_{n-1} -produkcje: ich lewe strony muszą zaczynać się terminalem lub nieterminalem A_n więc możemy je z Lematu 1 zastąpić prawymi stronami A_n -produkcji (wszystkie zaczynają się terminalem). I tak do A_1 .

Łatwo zauważyć że B -produkje nigdy nie zaczynają się nieterminalem B więc też z Lematu 1 możemy je zastąpić prawymi stronami A -produkcji.

Przykład

$$\begin{aligned} A_1 &\rightarrow A_2 A_3 \\ A_2 &\rightarrow A_3 A_1 | b \\ A_3 &\rightarrow A_1 A_2 | a \end{aligned}$$

Nie pasuje $A_3 \rightarrow A_1 A_2$ więc z Lematu 1 dostajemy $A_3 \rightarrow A_2 A_3 A_2$.

Dalej nie pasuje więc ponownie z Lematu 1 otrzymujemy $A_3 \rightarrow A_3 A_1 A_3 A_2 | b A_3 A_2$.

Teraz mamy $A_3 \rightarrow A_3 A_1 A_3 A_2 | b A_3 A_2 | a$, korzystamy z Lematu 2 i otrzymujemy $A_3 \rightarrow a | a B_3 | b A_3 A_2 | b A_3 A_2 B_3$ i $B_3 \rightarrow A_1 A_3 A_2 | A_1 A_3 A_2 B_3$.

Przykład

Teraz odpowiednio podstawiając zgodnie z Lematem 1 otrzymujemy

$$\begin{aligned} A_3 &\rightarrow a|aB_3|bA_3A_2|bA_3A_2B_3 \\ A_2 &\rightarrow aA_1|aB_3A_1|bA_3A_2A_1|bA_3A_2B_3A_1|b \\ A_1 &\rightarrow aA_1A_3|aB_3A_1A_3|bA_3A_2A_1A_3|bA_3A_2B_3A_1A_3|bA_3 \\ B_3 &\rightarrow aA_1A_3A_2|aB_3A_1A_3A_2|bA_3A_2A_1A_3A_2| \\ &\quad bA_3A_2B_3A_1A_3A_2|bA_3A_3A_2|aA_1A_3A_3A_2B_3| \\ &\quad aB_3A_1A_3A_2B_3|bA_3A_2A_1A_3A_3A_2B_3| \\ &\quad bA_3A_2B_3A_1A_3A_3A_2B_3|bA_3A_3A_2B_3 \end{aligned}$$

Notatki

[illegible]

Notatki

[illegible]

Notatki

[illegible]

Notatki

[illegible]